Note explicative — Calculs de puissance et de taille d'effet minimale détectable (MDE)

Projet « Normes de genre, corvées domestiques, éducation et aspirations des filles au Bénin »

CKDev / Dartmouth College — PI : M. Yedomiffi Préparé à partir du script `power_gender_norm.do` et de son log d'exécution du 10/09/2026

1. Objectif de cette note

Le script Stata analysé calcule, pour un essai randomisé en grappes (cluster-randomized trial) à 3 bras (Contrôle / T1 « Salience » / T2 « Salience + Mise en œuvre »), trois familles de questions :

Combien d'écoles par bras faut-il pour détecter de façon fiable un effet donné (en particulier l'effet de 20 %, soit 0,20 écart-type, explicitement demandé) ?
Quel est l'effet minimum détectable (MDE) avec le design actuellement prévu (150 écoles, 50 par bras, 30 filles par école) ?
Comment ce MDE évolue-t-il selon l'ICC (paramètre de corrélation intra-école), l'ajout de covariables de base (ANCOVA), l'attrition attendue, ou le type d'outcome (continu vs binaire) ?

Cette note (i) définit tous les termes techniques utilisés, (ii) traduit les résultats du log en langage clair pour le PI/l'équipe KCDev, et (iii) explique comment réutiliser le fichier `.do`.

2. Concepts clés et vocabulaire technique

2.1 Randomisation en grappes (« cluster randomized design »)

Ici, l'unité randomisée n'est pas la fille (l'unité d'observation) mais **l'école** (l'unité de randomisation). Toutes les filles d'une même école reçoivent le même traitement. Ce choix évite la « contamination » entre parents d'une même école mais réduit la puissance statistique par rapport à une randomisation individuelle, car les filles d'une même école ont tendance à se ressembler sur l'outcome (cf. ICC ci-dessous).

2.2 Seuil de signification — `alpha`

Probabilité de conclure à tort qu'il y a un effet alors qu'il n'y en a pas (« faux positif »). Convention : **alpha = 0,05** (5 %), test bilatéral.

2.3 Puissance statistique — `power`

Probabilité de détecter un effet réel s'il existe (probabilité de ne **pas** commettre de « faux négatif »). Convention académique standard : **power = 0,80** (80 %). C'est la probabilité que l'étude, si l'effet existe vraiment, produise un résultat statistiquement significatif.

2.4 Effet minimum détectable — `MDE` (delta dans les tableaux Stata)

C'est la plus petite différence entre le groupe traité et le groupe contrôle que le design est capable de détecter avec la puissance et le seuil choisis. Il est exprimé ici **en écarts-types (SD) de l'outcome**, car aucune donnée de base (pilote) n'existe encore : on travaille donc en variables « standardisées » (moyenne = 0, écart-type = 1). Un MDE de 0,20 signifie « le design peut détecter un effet égal à 20 % d'un écart-type de l'outcome, pas moins ». Plus le MDE est petit, plus le design est puissant (mais plus il faut d'échantillon).

Remarque pratique : « effet de 20 % » est un raccourci de langage pour « effet de 0,20 écart-type », une unité standard en économie du développement (dite *taille d'effet standardisée* ou *Cohen's d*). Ce n'est **pas** 20 % du niveau moyen de l'outcome.

2.5 Coefficient de corrélation intra-classe — `ICC` / `rho`

C'est **le paramètre le plus déterminant et le plus incertain** de tout le calcul. Il mesure à quel point les filles d'une même école se ressemblent entre elles sur l'outcome, comparé à des filles d'écoles différentes (valeurs entre 0 et 1) :

rho = 0 → les filles d'une même école ne se ressemblent pas plus que des filles d'écoles différentes (comme si l'échantillon était randomisé au niveau individuel — cas le plus favorable).
rho élevé (proche de 1) → les filles d'une même école sont presque identiques entre elles sur l'outcome ; ajouter des filles dans une même école n'apporte alors presque plus d'information nouvelle (cas le plus défavorable).

Conséquence pratique : plus l'ICC est élevé, plus il faut d'écoles (et non simplement plus de filles) pour conserver la même puissance. Comme aucune donnée pilote n'existe, le script teste une plage plausible : rho = 0,05 / 0,10 / 0,15 / 0,20, avec 0,10 comme hypothèse centrale. Une fois des données de terrain disponibles, l'ICC réel s'estime avec la commande Stata `loneway` sur les données pilotes.

2.6 Nombre de grappes et ratio de grappes — `k1`, `k2`, `kratio`

`k1` = nombre d'écoles dans le groupe de référence (souvent le contrôle).
`k2` = nombre d'écoles dans le groupe comparé (souvent le traitement).
`kratio` = k2 / k1 (ici toujours 1, car on prévoit un nombre égal d'écoles par bras).

2.7 Taille par grappe et ratio — `m1`, `m2`, `mratio`

`m1` / `m2` = nombre de filles enquêtées par école dans chaque groupe (ici 30 : 15 en 6e et 15 en 5e).
`mratio` = m2 / m1 (ici 1, même nombre de filles par école dans les deux groupes).

2.8 Écart-type de l'outcome — `sd`

Dispersion de l'outcome dans la population. Fixé à 1 ici car l'outcome est standardisé (pas encore de données réelles). À remplacer plus tard par l'écart-type réel de l'indicateur mesuré (temps consacré aux corvées, score de test, etc.).

2.9 `power twomeans` vs `power twoproportions`

`power twomeans` : utilisé pour un outcome **continu** (ex. nombre d'heures de corvées, score d'aspiration). Le paramètre clé est `sd` (écart-type).
`power twoproportions` : utilisé pour un outcome **binaire** (oui/non), par exemple « la fille dispose-t-elle d'un créneau d'étude protégé ? ». Ici, pas besoin de `sd` séparé : la variance est automatiquement déduite de la proportion de référence (`p1`) et de la proportion attendue dans le groupe traité (`p2`).

2.10 Ajustement ANCOVA (covariable de base) — `R²`

Si l'on dispose d'une mesure de l'outcome **avant** l'intervention (baseline) et qu'on l'utilise comme variable de contrôle dans la régression finale, on réduit la variance résiduelle non expliquée, donc on **améliore la puissance** (MDE plus petit) sans changer la taille d'échantillon. Le `R²` de baseline indique la part de la variance de l'outcome final expliquée par les covariables de base (ex. 20-40 % typiquement observé dans les études d'éducation/usage du temps).

2.11 Attrition

Proportion de filles/ménages perdus entre l'enquête de référence (baseline) et l'enquête finale (endline) — refus, déménagement, absence, etc. L'attrition réduit le nombre effectif de filles suivies par école (`m1_eff`), donc dégrade légèrement la puissance / augmente le MDE.

2.12 Randomisation emboîtée (« nested ») mère vs père

À l'intérieur des bras traités (T1 et T2), les écoles sont en plus randomisées entre un ciblage « mère » et un ciblage « père » du message. Cette comparaison secondaire dispose de **moins d'écoles** que la comparaison principale (traitement vs contrôle), car elle n'utilise que les écoles déjà traitées : elle est donc **mécaniquement moins puissante** (MDE plus grand).

3. Interprétation des résultats du log

3.1 Question centrale : combien d'écoles par bras pour détecter un effet de 20 % (0,20 SD) ?

(Bloc « Nouveau Bloc 2 », Table 0 et Table 0bis du log)

Avec 30 filles enquêtées par école (design initial), le nombre d'écoles nécessaires **par bras** varie fortement selon l'hypothèse d'ICC :

ICC (rho)	Écoles nécessaires / bras	Effectif total de filles
0,05	33	1 980
0,10 (hypothèse centrale)	**52**	**3 120**
0,15	70	4 200
0,20	89	5 340

Lecture : avec l'hypothèse centrale (ICC = 0,10), il faudrait environ 52 écoles par bras (156 au total) pour détecter de façon fiable un effet de 0,20 SD — soit légèrement plus que les 50 écoles par bras (150 au total) actuellement prévues dans le guide de projet. Le design prévu est donc « à la limite » : suffisant si l'ICC réel est ⩽ 0,10, insuffisant si l'ICC réel est plus élevé (0,15-0,20, plage plausible pour des indicateurs de normes sociales).

Solution de compromis identifiée (Table 0bis) : en gardant 50 écoles/bras (budget déjà prévu) mais en enquêtant **35 filles par école au lieu de 30**, on atteint la puissance requise pour détecter 0,20 SD à ICC central = 0,10. Augmenter davantage le nombre de filles par école (au-delà de 35-40) rapporte de moins en moins, précisément à cause de l'ICC (voir §2.5) : ajouter des filles dans une même école a des rendements décroissants sur la puissance.

3.2 MDE effectivement atteignable avec le design prévu (50 écoles/bras, 30 filles/école)

(Table 1)

ICC	MDE (en SD)
0,05	0,160
0,10	**0,202**
0,15	0,237
0,20	0,267

Lecture : avec le design tel que prévu aujourd'hui, la comparaison principale (T1 vs Contrôle, ou T2 vs Contrôle) peut détecter un effet d'environ 0,20 SD si l'ICC réel est proche de 0,10 — cohérent avec le §3.1. Si l'ICC réel est plus élevé, le plus petit effet détectable augmente (jusqu'à ~0,27 SD si ICC = 0,20), c'est-à-dire que l'étude perd la capacité de détecter des effets plus modestes.

3.3 Combien d'écoles pour d'autres cibles d'effet (0,15 / 0,25 / 0,30 SD) ?

(Table 2) — Utile pour situer le design prévu par rapport à d'autres hypothèses d'effet :

Viser un effet plus **petit** (0,15 SD, plus ambitieux) exige beaucoup plus d'écoles : 57 à 159 selon l'ICC.

Viser un effet plus **grand** (0,25 ou 0,30 SD, plus modeste comme ambition) demande beaucoup moins d'écoles : 15 à 57 selon l'ICC.

Ceci illustre la sensibilité classique : diviser par deux le MDE visé multiplie approximativement par quatre le nombre d'écoles nécessaires.

3.4 Gain de puissance avec une covariable de base (ANCOVA)

(Table 3, à ICC central = 0,10, 50 écoles/bras)

R^2 de base	MDE (SD)
0 % (pas de covariable)	0,202
10 %	0,192
20 %	0,181
30 %	0,169
40 %	0,156

Lecture : si l'on dispose d'une mesure de l'outcome avant l'intervention (baseline) qui explique par exemple 30 % de la variance de l'outcome final, le MDE passe de 0,202 à 0,169 SD — un gain de précision non négligeable, à taille d'échantillon inchangée. Ceci plaide pour la collecte d'une enquête de référence (baseline) sur les mêmes indicateurs que ceux mesurés à l'endline.

3.5 Effet de l'attrition attendue

(Table 4, à ICC central = 0,10, 50 écoles/bras)

Taux d'attrition	Filles suivies / école (effectif)	MDE (SD)
5 %	28,5	0,203
10 %	27	0,205
15 %	25,5	0,206
20 %	24	0,208

Lecture : même avec une attrition élevée (20 %), la dégradation du MDE reste modeste (0,202 → 0,208 SD) parce que le nombre d'écoles — le facteur le plus puissant sur la précision dans un design en grappes — ne change pas. L'attrition affecte surtout le nombre de filles par école, qui a un impact plus faible sur la puissance que le nombre d'écoles.

3.6 Comparaison secondaire mère vs père (randomisation emboîtée)

(Bloc 7)

À l'intérieur d'un seul bras traité (25 écoles « mère » vs 25 écoles « père ») : MDE = **0,286 SD**.
En regroupant les deux bras traités (50 écoles « mère » vs 50 écoles « père ») : MDE = **0,202 SD**.

Lecture : la comparaison mère vs père est nettement moins puissante que la comparaison principale traitement vs contrôle si elle est faite à l'intérieur d'un seul bras (0,286 SD contre 0,202 SD). Elle rejoint la précision de la comparaison principale seulement si l'on regroupe les deux bras traités**. Point à signaler explicitement au PI** : les conclusions sur la comparaison mère/père (section 5.3 du guide projet) devront être interprétées avec cette limite de puissance à l'esprit, en particulier si l'analyse est faite bras par bras plutôt qu'en poolant.

3.7 Cas d'un outcome binaire (ex. « créneau d'étude protégé »)

(Table 5, hypothèse : 30 % des filles du groupe contrôle ont l'outcome)

Effet visé (points de %)	Puissance atteinte
+10 points (30 % → 40 %)	83,0 %
+15 points (30 % → 45 %)	99,1 %
+20 points (30 % → 50 %)	99,99 %

Lecture : avec le design prévu, l'étude a largement la puissance nécessaire (>80 %) pour détecter un effet de 10 points de pourcentage ou plus sur un outcome binaire dont la prévalence de référence est de 30 %. Ce type d'outcome est donc moins « à risque » sur le plan de la puissance que les outcomes continus visés à 0,20 SD.

3.8 Graphique de sensibilité (MDE selon le nombre d'écoles et l'ICC)

Le fichier `MDE_sensitivity_CKDev_Benin.png` produit par le script trace, pour chaque hypothèse d'ICC (0,05 à 0,20), la courbe du MDE en fonction du nombre d'écoles par bras (de 20 à 90), avec deux lignes de repère : 50 écoles/bras (design prévu) et 0,20 SD (effet cible). Ce graphique permet de visualiser en un coup d'œil que la ligne « 50 écoles » croise la ligne « 0,20 SD » approximativement au niveau de la courbe ICC = 0,10, confirmant numériquement les résultats du §3.2.

4. Synthèse pour le PI / l'équipe KCDev

Le design actuellement prévu (150 écoles, 50/bras, 30 filles/école) est globalement adapté pour détecter un effet de 0,20 SD, mais seulement si l'ICC réel est proche de 0,10.

Le principal risque identifié est l'incertitude sur l'ICC. Si l'ICC réel se situe entre 0,15 et 0,20 (plausible pour des indicateurs de normes sociales/usage du temps), il faudrait 70 à 90 écoles par bras pour conserver la même capacité de détection — soit 20 à 40 écoles de plus par bras que prévu.
Deux leviers d'atténuation, sans changer le nombre d'écoles :
Augmenter légèrement le nombre de filles enquêtées par école (35 au lieu de 30) suffit à couvrir le scénario central (ICC = 0,10).
Collecter une enquête de référence (baseline) sur les mêmes outcomes pour bénéficier d'un ajustement ANCOVA, qui réduit le MDE à budget d'échantillon inchangé.
La comparaison secondaire mère vs père est structurellement moins puissante que la comparaison principale et devra être analysée en poolant les deux bras traités pour espérer une précision comparable.
Action recommandée avant la finalisation du design : dès que des données pilotes ou une enquête de référence comparable sont disponibles, réestimer l'ICC réel avec `loneway` (voir §2.5) et refaire tourner ce script pour remplacer l'hypothèse centrale de 0,10 par la valeur observée.

5. Mode d'emploi : comment réutiliser le fichier `.do`

Pré-requis : Stata 17 ou plus (commande `power` disponible depuis Stata 14).
Adapter le chemin de travail en modifiant la ligne `cd "C:\RONALDO\CKDEV\..."` en haut du fichier vers votre propre dossier de travail.
Paramètres à ajuster en priorité (repérés par le commentaire `//SPECIFY` dans le fichier) :
`n_schools_per_arm`, `n_girls_per_school` : le design envisagé.
`alpha_level`, `power_target` : les conventions statistiques (généralement à laisser à 0,05 / 0,80 sauf exigence particulière du bailleur).
`rho_central` et `rho_list` : l'hypothèse (ou la plage d'hypothèses) sur l'ICC — **à mettre à jour dès que des données réelles sont disponibles**, via `loneway <outcome> <ecole_id>`.
`target_mde_20` (bloc 2) et `target_mde_list` (bloc 4) : les tailles d'effet à tester.
`p_control` et `mde_pp_list` (bloc 8) : pour les outcomes binaires.
Exécuter le script en entier (`do power_gender_norm.do`) ou bloc par bloc — chaque bloc est autonome après exécution du Bloc 0 (housekeeping) et du Bloc 1 (paramètres).
Résultats produits automatiquement :
`Power_MDE_CKDev_Benin_summary.xlsx` : toutes les tables numériques, prêtes à partager avec le PI ou le bailleur.
`MDE_sensitivity_CKDev_Benin.png` : le graphique de sensibilité MDE / ICC / nombre d'écoles.
`power_gender_norm.log` : le journal complet de l'exécution (utile pour audit/réplication).
Dès que des données pilotes existent : remplacer les scalaires `sd_outcome`, `baseline_mean` et `rho_central` par les valeurs réelles calculées via :

stata

```
quietly sum <variable_outcome>
scalar sd_outcome   = r(sd)
scalar baseline_mean = r(mean)
loneway <variable_outcome> <identifiant_ecole>
scalar rho_central  = r(rho)
```

puis relancer le script pour obtenir des estimations de puissance fondées sur des données réelles plutôt que sur des hypothèses.

Note préparée à partir de l'adaptation du template J-PAL « Sample_Size_and_Power » (J-PAL, ressource « Calculs de puissance » ; dépôt GitHub J-PAL/Sample_Size_and_Power), adaptation réalisée par Ronaldo Agbohou.